ECON-3527
INTELIGENCIA ARTIFICIAL APLICADA A LA ECONOMÍA

PREDICCIÓN DE PRECIOS DEL MERCADO INMOBILIARIO EN BOGOTÁ



Presentación de avance

Maria Paula Rivera, Angelo Di Marco y Santiago Muñoz

PROPUESTA INICIAL

¿Cuál debería ser el precio de una vivienda en Bogotá dadas sus características paramétricas como área, antigüedad y ubicación?

METODOLOGÍA Y DATOS

- Random Forest frente a una línea base de regresión lineal.
- Datos: base pública de Kaggle (Bogotá Apartments, web scraping desde 2024), 26,900 viviendas en venta (de 43,013 anuncios) y 36 variables.

MODELO MÉTODO CLÁSICO

LÍNEA BASE

REGRESIÓN LINEAL

Área, antigüedad, localidad, estrato y habitaciones

MODELOS COMPARADOS

- Lineal (línea base)
- Lineal completo
- Lasso
- Random Forest
- XGBoost

Cada uno con objetivo en log(precio) y en niveles

MÉTRICAS

RMSE · principal

Penaliza los errores grandes, los más costosos para comprador y vendedor

MAPE · secundaria

Error relativo al valor de la vivienda. Por estrato se añade el MAE

VALIDACIÓN

Partición

- 80/20 estratificada por estrato
- 21,520 en entrenamiento
- 5,380 en prueba
- Sin split temporal: datos entre julio y septiembre de 2024

Validación cruzada



RESULTADOS MÉTODO CLÁSICO

Modelo	Objetivo	RMSE CV	RMSE prueba	MAPE CV	MAPE prueba
Lineal (base)	log	463	433	16.9%	17.3%
Lineal (completo)	log	446	400	15.4%	15.8%
Lasso	log	448	401	15.5%	15.8%
Random Forest	log	365	322	12.0%	11.9%
XGBoost	log	358	321	12.2%	12.2%
Lineal (base)	niveles	509	473	35.3%	36.3%
Lineal (completo)	niveles	497	460	36.5%	37.5%
Lasso	niveles	497	460	36.1%	37.1%
Random Forest	**niveles**	**355**	**310**	**12.7%**	**12.7%**
XGBoost	niveles	361	328	13.4%	13.5%

RMSE en millones de COP. CV: 5 folds sobre entrenamiento. En naranja, el menor RMSE de CV; en gris, la línea base.

MODELO ESCOGIDO

Random Forest (niveles) frente a la línea base:

- En log (la mejor): −28.4% RMSE y −4.6 pp MAPE
- En niveles: −34.5% RMSE y −23.6 pp MAPE

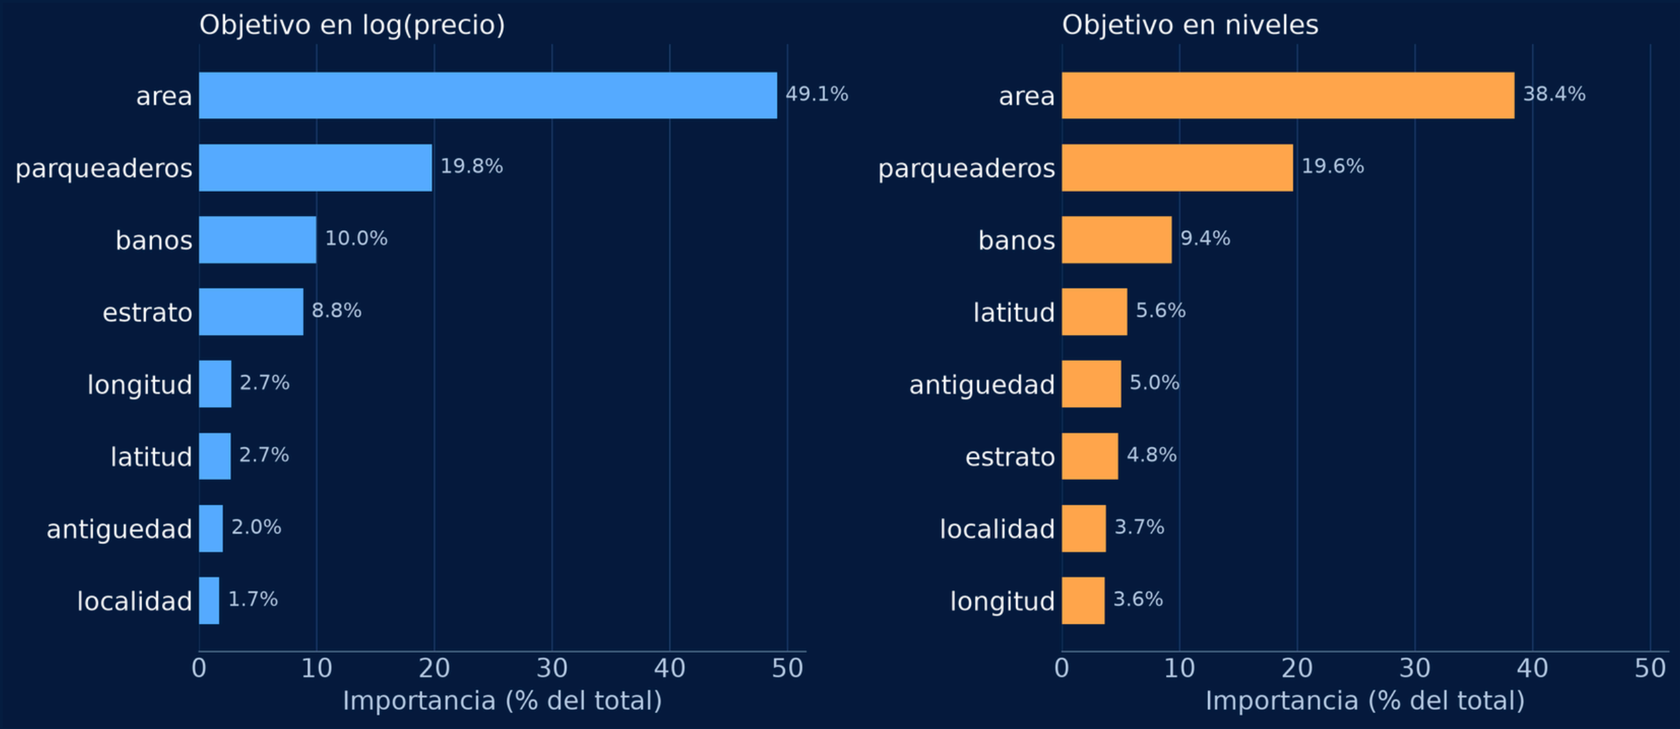
Aclaración

Todos los árboles presentan resultados de RMSE CV muy parecidos

- RF niveles = 355
- XGBoost log = 358
- XGBoost niveles = 361
- RF log = 365

IMPORTANCIA DE VARIABLES

RANDOM FOREST: QUÉ VARIABLES EXPLICAN EL PRECIO



Área, parqueaderos y baños suman 67.4% (niveles) y 78.8% (log).

Ubicación (latitud, longitud, localidad) y estrato: 17.7% (niveles) y 16.0% (log).

Importancia por reducción de impureza; no tiene interpretación causal.

DIAGNÓSTICO DE OBSTÁCULOS

DATOS Y MUESTRA: QUÉ HICIMOS Y QUÉ HAREMOS

EVIDENCIA

1. Precio publicado, no de transacción
2. Datos solo de julio a septiembre de 2024
3. Estrato 6: 43.6% de prueba; estrato 1: 16 viviendas
4. Barrio está altamente correlacionado con localidad y estrato
5. 424 anuncios idénticos salvo código y fechas

QUÉ HICIMOS

1. El error se mide frente al precio de oferta
2. Partición aleatoria 80/20, sin split temporal
3. Partición estratificada; se marcan grupos < 30
4. Barrio fuera del modelo; ubicación por lat/lon
5. Eliminados; se conserva el más reciente

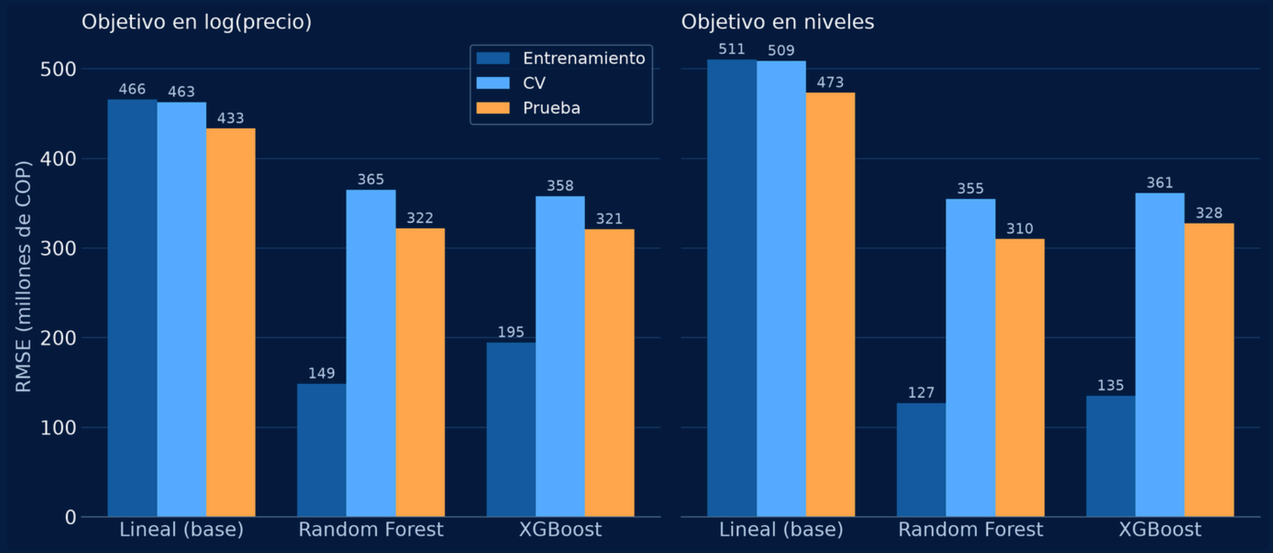
QUÉ HAREMOS

1. Advertirlo en cada cifra para el usuario
2. Revalidar cada trimestre con anuncios nuevos
3. Ampliar la muestra de estrato 1 y la periferia
4. Estimar el modelo con y sin estrato y localidad
5. Reportar la sensibilidad a gemelos en cada corrida

DIAGNÓSTICO DE OBSTÁCULOS

ESPECIFICACIÓN, SOBREAJUSTE Y ACCESO A DATOS

- Lineal en niveles: 218 de 5,380 predicciones de prueba son negativas (242 en el lineal completo, 234 en Lasso).
- El Random Forest sin CV memoriza el entrenamiento (RMSE 127 M frente a 355 M en CV) – hiperparámetros solo por CV
- CV y prueba (310 M) difieren menos que la desviación entre folds (65 M).
- CV elige el número mínimo de observaciones por hoja como 1, el mínimo valor posible: subirlo a 5 lleva el RMSE de CV de 355 a 368 M.
- La propuesta elegía Random Forest por menor sobreajuste que XGBoost, pero en CV quedan a menos de una desviación (355 frente a 361 M) → se mantiene por interpretabilidad, sin ventaja demostrada.

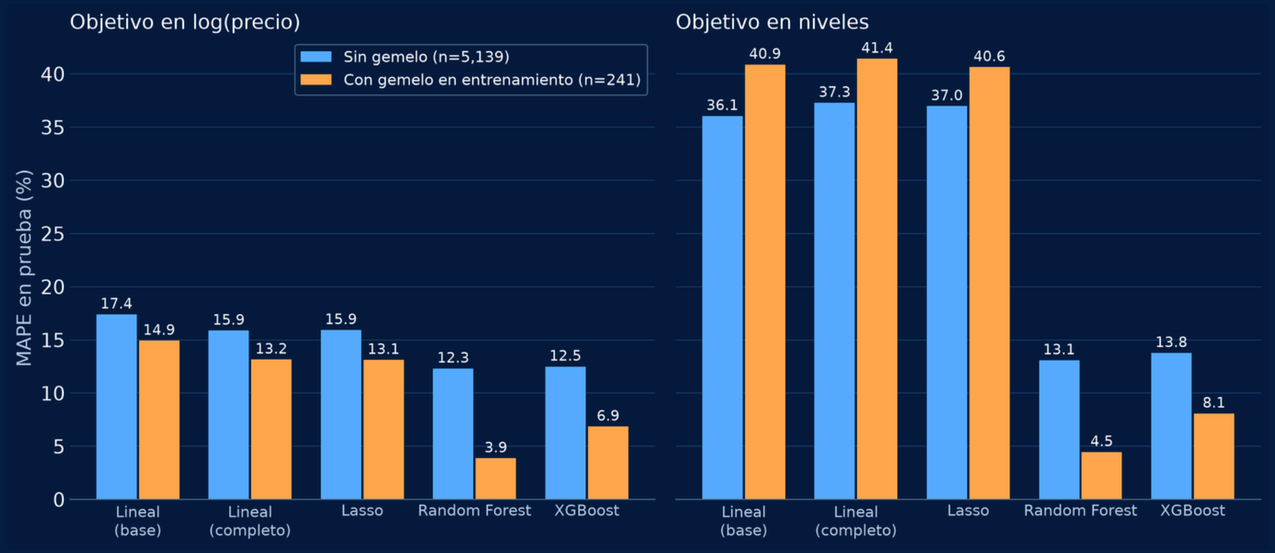


RMSE en millones de COP. Se compara CV con prueba; el error de entrenamiento es solo descriptivo.

DIAGNÓSTICO DE OBSTÁCULOS

ANUNCIOS REPETIDOS: EL MISMO INMUEBLE CON OTRO CÓDIGO

- Detección: el mismo inmueble aparece varias veces con códigos distintos, republicado por la misma inmobiliaria o por varias.
- Si queda uno en entrenamiento y otro en prueba, el modelo evalúa una vivienda que ya vio: fuga de información.
- Se eliminaron 424 anuncios idénticos en todo salvo código y fechas (288 grupos); se conserva el más reciente.
- Los que difieren en descripción o atributos se conservan: pueden ser unidades distintas del mismo edificio.
- Quedan 241 viviendas de prueba (4.5%) con un gemelo en entrenamiento (misma área, precio, coordenadas y habitaciones).

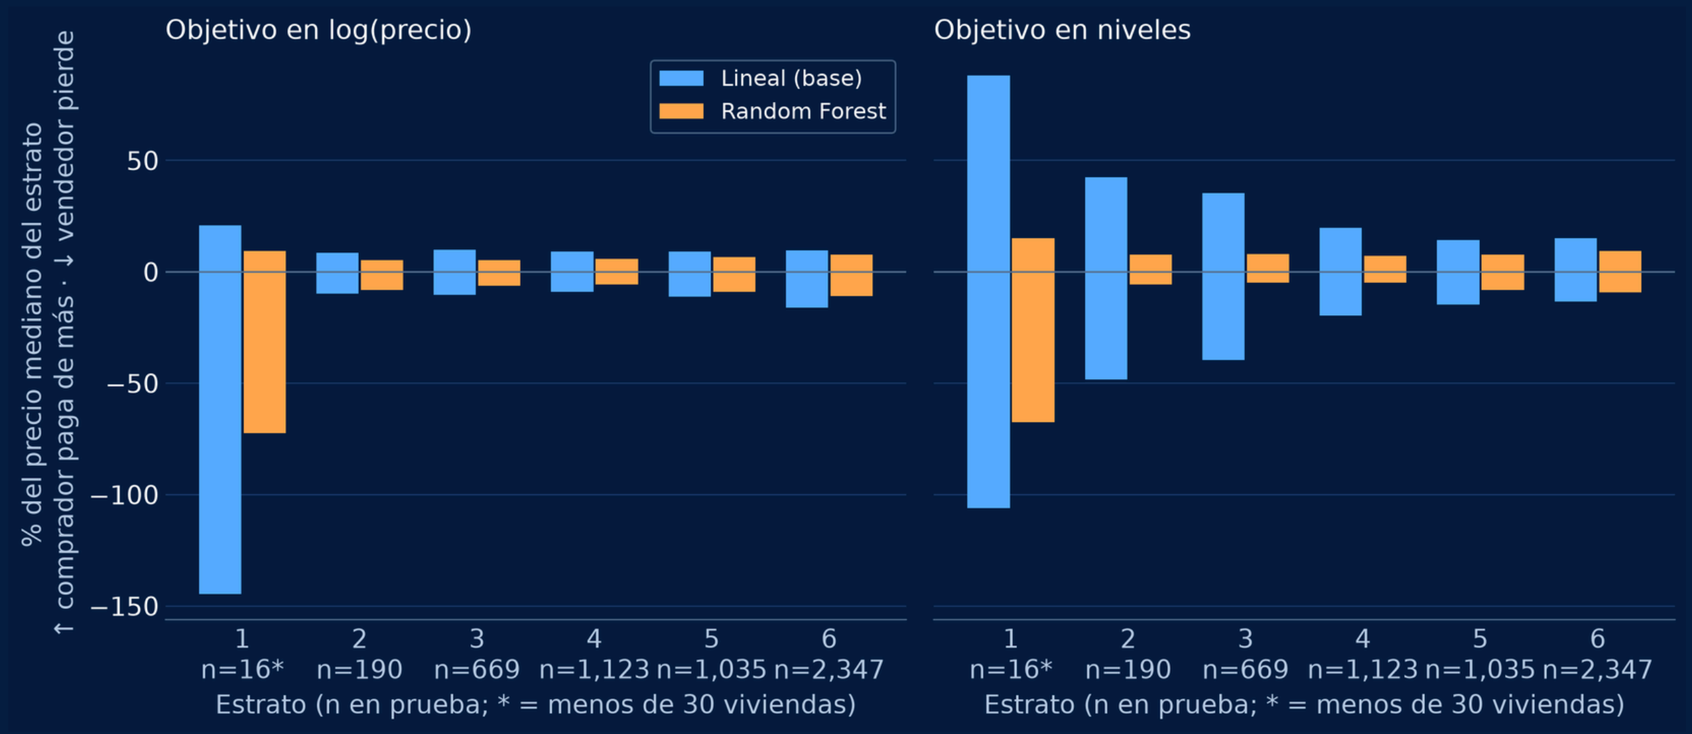


Random Forest (niveles): MAPE de 4.5% en las viviendas con gemelo y de 13.1% en las demás; en el total pasa de 12.7% a 13.1% sin ellas. Se reportan ambas cifras.

EVALUACIÓN

RANDOM FOREST PARA ESTIMAR EL PRECIO DE LA VIVIENDA

Costo esperado del error de precio por vivienda, en prueba y por estrato



SOBRECOSTO ESPERADO COMPRADOR

Niveles:

- Línea Base: 141 M
- Random Forest: 76 M

Log:

- Línea Base: 82 M
- Random Forest: 62 M

PÉRDIDA ESPERADA VENDEDOR

Niveles:

- Línea Base: 133 M
- Random Forest: 72 M

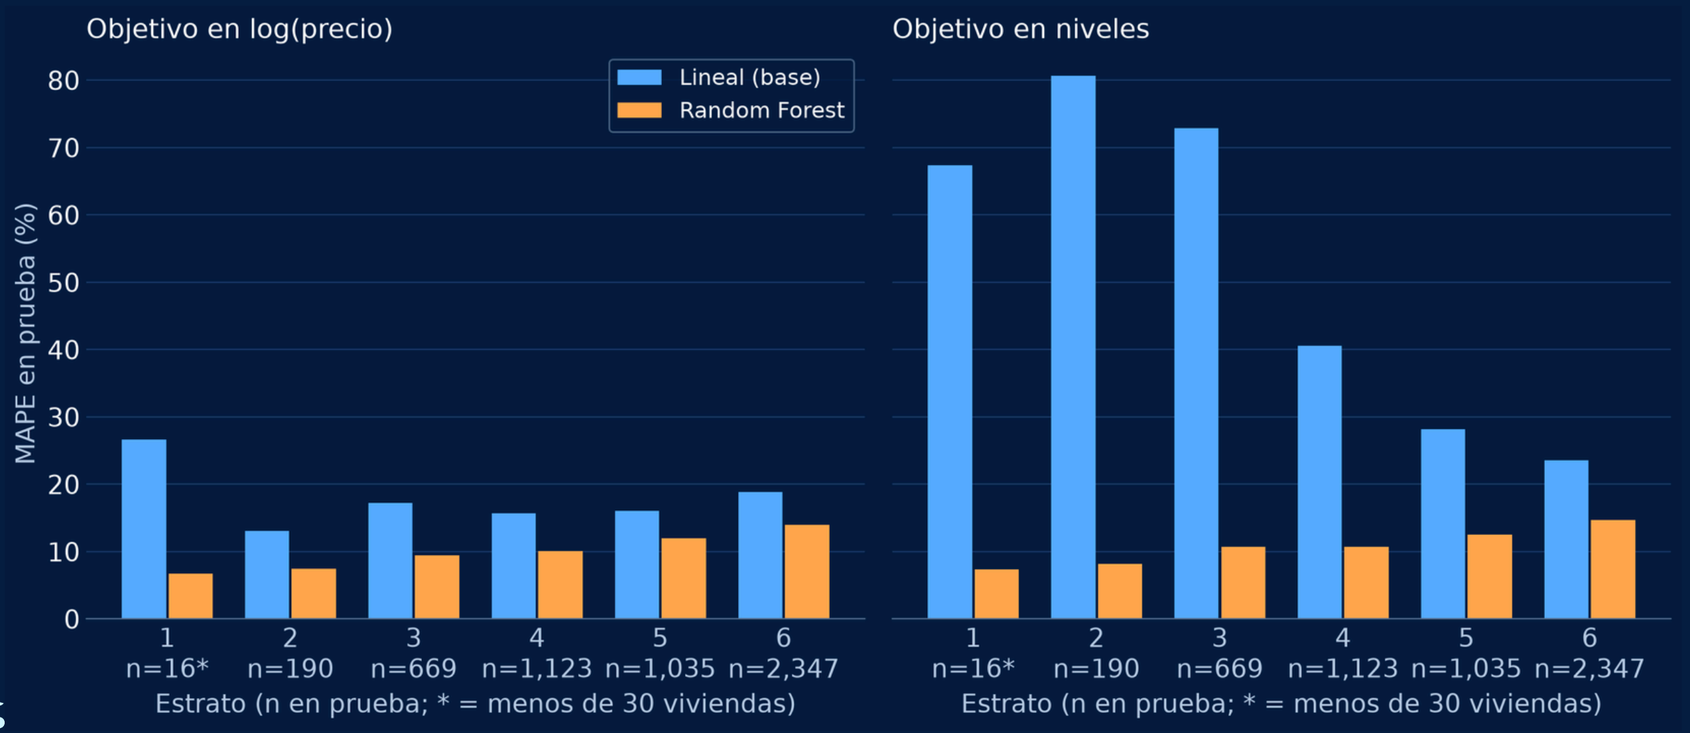
Log:

- Línea Base: 123 M
- Random Forest: 85 M

EVALUACIÓN

RANDOM FOREST PARA ESTIMAR EL PRECIO DE LA VIVIENDA

Error relativo (MAPE) en prueba por estrato y prueba A/B propuesta



Reducción observada del error relativo:

- 5.4 pp (log)
- 23.6 pp (niveles).

Viviendas por brazo para detectarla:

- 144 (log): tamaño a usar
- 26 (niveles; su base da precios negativos)
- α = 0.05 y potencia 0.80.

OBJETIVOS PRÁCTICOS

CÓMO USAR EL PRECIO ESTIMADO PARA DECIDIR

QUIÉN LO USA

- Comprador: comparar el precio publicado con el estimado antes de ofertar.
- Vendedor: fijar el precio de salida cerca del estimado.
- Inmobiliaria: revisar los anuncios lejos del estimado.
- Banco: alerta previa al avalúo, no un reemplazo.
- Si la diferencia supera la banda del estrato, negociar o buscar comparables.

CUÁNTO SE EQUIVOCA

- Error mediano en prueba, por estrato:
- Estrato 2: 4.6% (8 M)
- Estrato 3: 6.7% (18 M)
- Estrato 4: 7.5% (33 M)
- Estrato 5: 8.4% (61 M)
- Estrato 6: 10.8% (137 M)
- Banda: 8 de cada 10 viviendas tienen un error menor a 14% (estrato 2) a 23% (estrato 6).

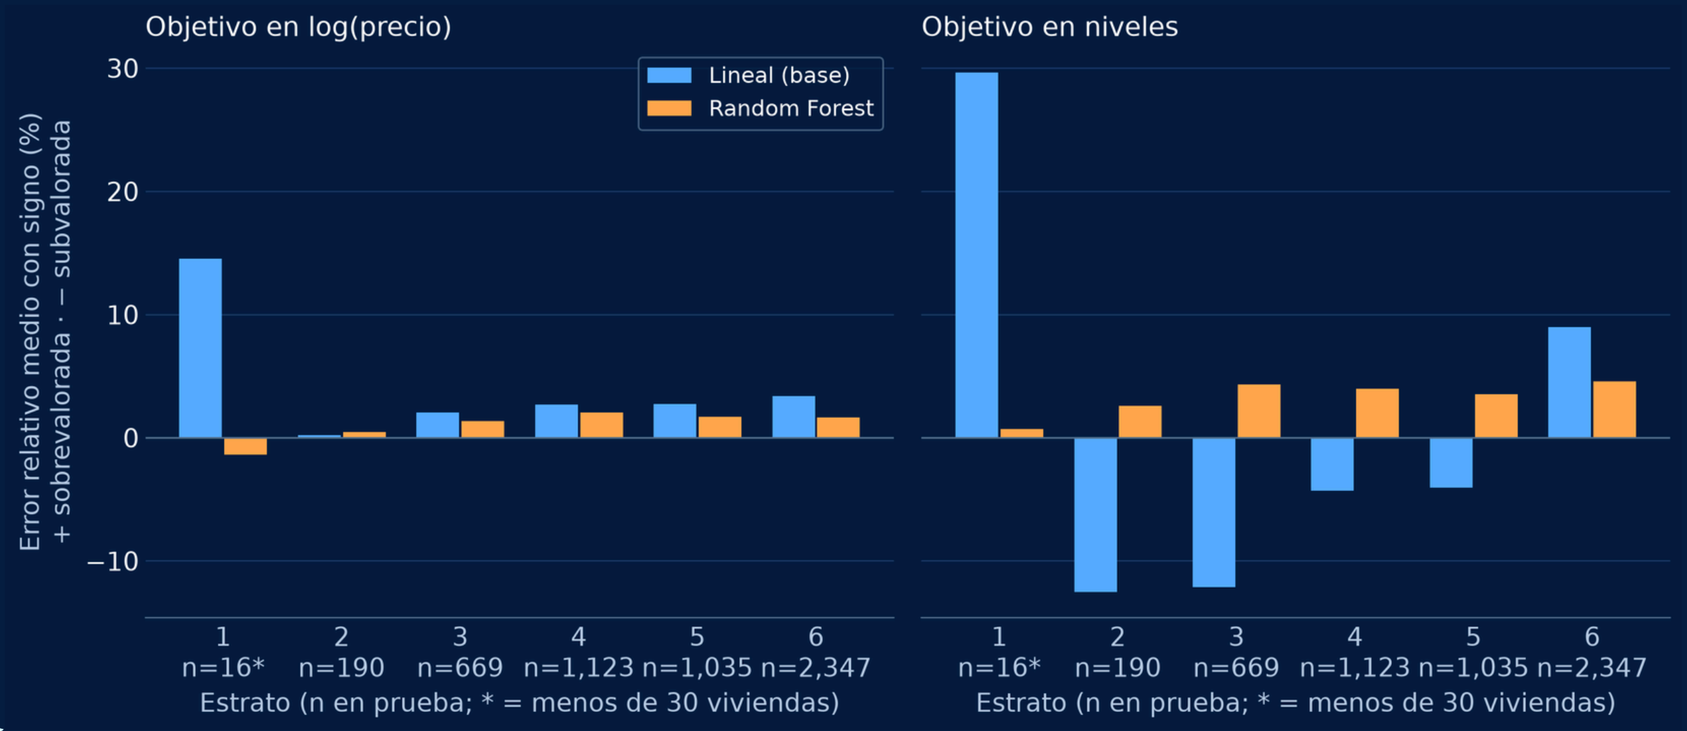
EJEMPLO EN PRUEBA

- Usaquén, estrato 3: 73 m², 3 habitaciones, 2 baños, sin parqueadero, 10 a 20 años.
- Publicado: 291.8 M
- Estimado: 272.3 M
- Diferencia: 19.4 M (6.7%), dentro de la banda del estrato 3 (16.8%).
- El comprador tiene un argumento para ofertar cerca de 272 M.

- *Random Forest (niveles), 5,380 viviendas de prueba; precio publicado, no de transacción.*
- *Estrato 1 (16 viviendas) no se interpreta.*

IA RESPONSABLE

ESTRATO Y LOCALIDAD: VARIABLES SENSIBLES Y ASOCIADAS ENTRE SÍ (V DE CRAMÉR ESTRATO–BARRIO 0.80)



Línea base (niveles):

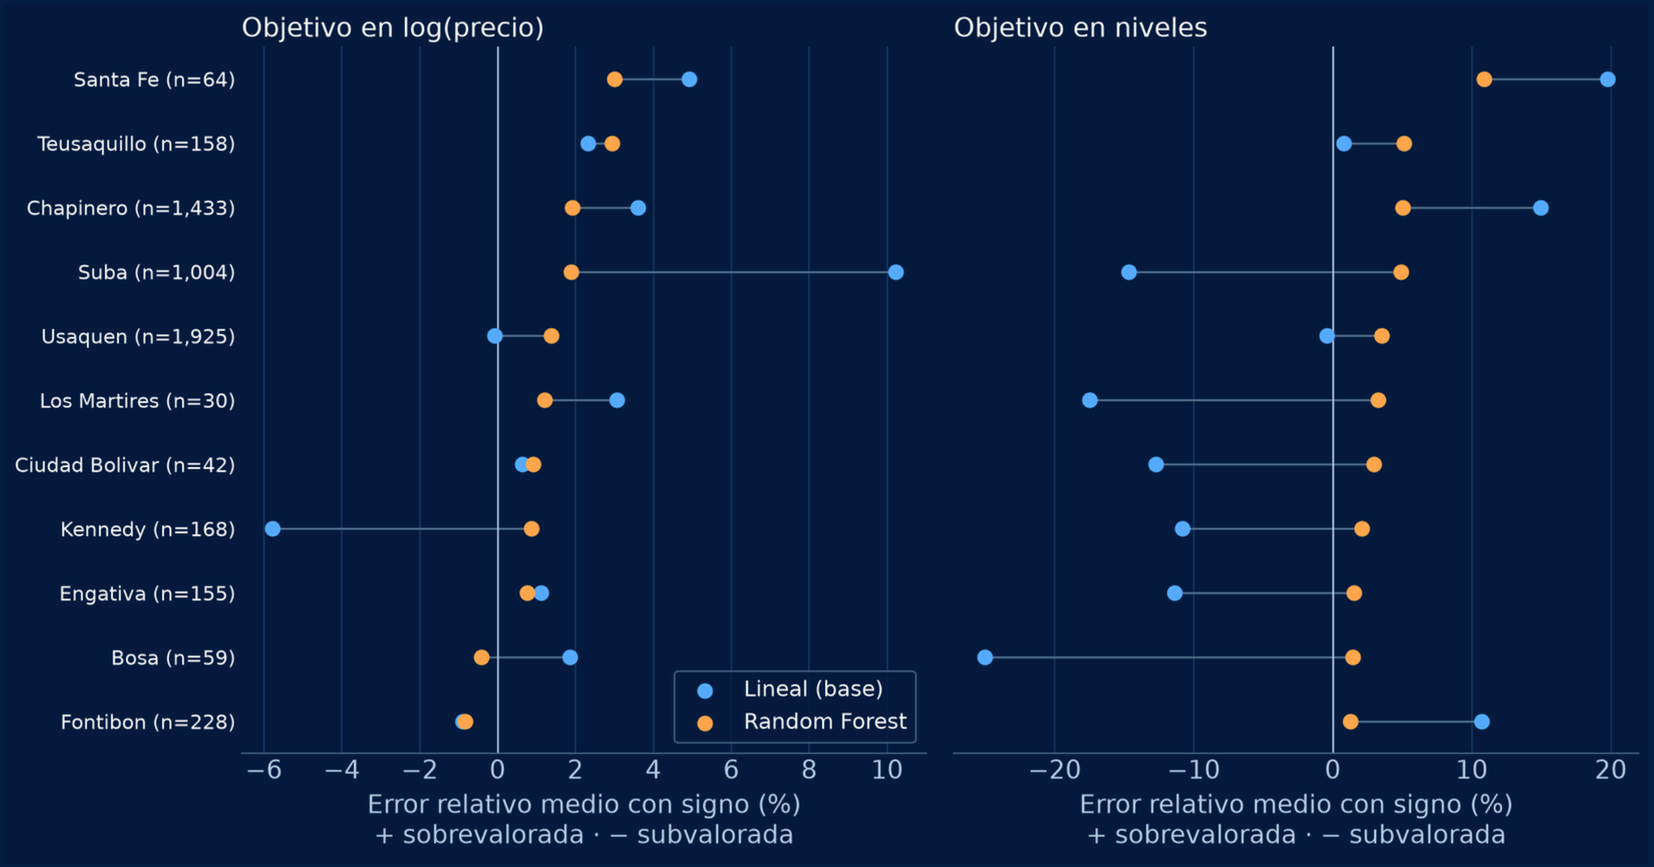
- Subvalora los estratos 2 y 3 (−12.5% y −12.1%)
- Sobrevalora el 6 (+9.0%).

Random Forest (niveles):

- Sobrevalora los estratos 2 a 6, entre +2.6% y +4.6%.

IA RESPONSABLE

ERRORES POR LOCALIDAD (CON AL MENOS 30 VIVIENDAS EN PRUEBA)



Random Forest (niveles):

- Rango de 1.3% (Fontibón) a +10.9% (Santa Fe)
- Chapinero +5.0% y Usaquen +4.0%

Línea base (niveles):

- Rango de -25.0% (Bosa) a 20% (Santa Fe)
- Suba -14.7% y Chapinero +15.0%.

Sin interpretar (n menor a 30): Candelaria, Antonio Nariño, Usme, Puente Aranda, Rafael Uribe Uribe, San Cristóbal, Tunjuelito y Barrios Unidos.

IA RESPONSABLE

ESTRATEGIAS DE MITIGACIÓN PROPUESTAS

- Reportar en cada revisión trimestral el error y el sesgo por estrato y localidad, marcando los grupos con menos de 30 viviendas.
- No usar el precio estimado como único criterio en créditos hipotecarios ni subsidios: contrastarlo con un avalúo o con comparables.
- Ampliar la muestra de estrato 1 y de las localidades periféricas, hoy con menos de 30 viviendas en prueba.
- Comparar el modelo con y sin estrato y localidad para medir cuánto de la predicción depende de ellas.
- Corregir la sobrevaloración del Random Forest en niveles (+2.6% a +4.6% en los estratos 2 a 6), ajustando la corrección solo con entrenamiento.

PROPUESTA APRENDIZAJE PROFUNDO

USAR EL TEXTO DE LA DESCRIPCIÓN PARA ESTIMAR EL PRECIO

POR QUÉ

- Random Forest solo usa variables tabulares
- El texto del anuncio (mediana de 75 palabras, presente en todas las viviendas) trae lo que no hay en columnas:
  - Vista (44% de los anuncios)
  - Balcón (30%)
  - Cercanías (21%)
  - Remodelado (15%)
  - Iluminación (14%).

CÓMO

1. Convertir cada descripción en un vector con un modelo de lenguaje preentrenado en español.
2. Combinarlo con las variables actuales en una red neuronal que estima el precio.
3. Evaluarla con la misma partición y las mismas métricas (RMSE y MAPE), frente a la línea base y al Random Forest.

CAUTELAS

- El texto puede delatar el barrio o el estrato: auditar los errores por estrato y localidad.
- La descripción la escribe el vendedor y acompaña un precio publicado – podría capturar la habilidad para vender además de características del inmueble.
- Con 21,520 anuncios de entrenamiento, usar vectores preentrenados.

Ejemplo de los datos (Chapinero, estrato 5): "apartamento duplex remodelado para venta en el chico de 152.54 mts. [...] ultimo piso con vista exterior. dos garajes y deposito."

REFERENCIAS

- erik172. (2024). Bogota Apartments [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/erik172/bogota-apartments
- Jaimes, C. (2026, agosto 5). Bogotá salva el mercado de vivienda en Colombia: Ventas VIS se disparan mientras el resto del país cae. https://www.valoraanalitik.com/venta-de-vivienda-en-colombia-mercado-en-bogota-supera-el-resto-del-pais/
- Monsalve Martínez, M. C. (2026, julio 17). Bogotá concentra el 63% de toda la demanda inmobiliaria registrada en el país durante el primer semestre. Portafolio.co. https://www.portafolio.co/mis-finanzas/vivienda/bogota-concentra-el-63-de-toda-la-demanda-inmobiliaria-registrada-en-el-pais-durante-el-primer-semestre-498335
- Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.